



발표 준비 Q&A 예상 질문 및 답변 가이드

딥러닝 기반 트렌드 예측 모델 및 분석 결과 관련 검증 질문 대비 자료

[핵심 요약]

LSTM보다 빠르고 가벼운 GRU의 장점을 그대로 가져가면서, 데이터를 앞뒤 양방향으로 동시에 훑어 시간적 맥락(Context)을 놓치지 않고 입체적으로 파악할 수 있도록 고도화된 시계열/자연어 처리용 딥러닝 알고리즘입니다.

※ 발표 중 질의응답에서 질문이 나온다면, "과거의 흐름뿐만 아니라 전체 시퀀스 내에서 트렌드의 가속도와 전후 맥락을 입체적으로 짚어내기 위해, 연산이 효율적인 GRU에 양방향 구조를 결합한 Bi-GRU를 사용했습니다."라고 답변하시면 좋습니다.

Q1. 일반적인 LSTM 대신 BiGRU를 선택한 특별한 이유가 있나요?

💡 답변 가이드

GRU는 LSTM에 비해 게이트 구조가 단순하여 연산 속도가 빠르고 파라미터 수가 적어, 저희가 가진 데이터 규모에서 과적합(Overfitting)을 방지하는 데 더 유리했습니다. 또한, 양방향(Bi-directional) 구조를 사용해 트렌드의 전후 맥락과 가속도 변화를 더 입체적으로 포착하기 위해 BiGRU를 채택했습니다.

Q2. '상승 가능성이 높다'를 정의한 메인 타겟(rise_label)의 구체적인 기준(Threshold)이 무엇인가요?

💡 답변 가이드

'현재 4주 평균 반응 수준' 대비 '다음 4주 평균 반응 수준'의 상대 성장률을 계산했습니다. 단순히 성장률이 0보다 큰 경우가 아니라, 전체 데이터의 상위 특정 백분위수(또는 특정 성장률 값, 예: 5% 이상 등 구체적 수치 언급 가능) 이상으로 의미 있게 급상승한 시점을 1(상승)로, 그렇지 않은 경우를 0으로 라벨링했습니다.

Q3. 캘린더 변수(공휴일, 시험기간 등)를 넣었을 때 모델 성능이 실제로 얼마나 향상되었나요? (Ablation Study 여부)

💡 답변 가이드

캘린더 변수와 구글 트렌드를 제외하고 내부 시계열 데이터만으로 학습했을 때보다, 외부 변수를 포함했을 때 ROC AUC 및 Precision@5 성능이 약 0% 향상되었습니다. 특히 주차별로 급격한 변동이 생기는 '시험기간'이나 '연휴' 시점의 예측 오차가 크게 줄어드는 것을 확인했습니다.

Q4. 전체 16개 분야 중 최종 발표에서 10개 분야만 고정한 상세 기준이 무엇인가요? 빼버린 6개 분야는 무엇인가요?

 답변 가이드

주간 단위로 영상 업로드 수나 반응 지표의 총합이 너무 적어 시계열에 결측치(NaN)가 자주 발생하거나 변동성이 지나치게 큰 분야(예: 특정 비주류 카테고리 등)는 모델의 노이즈가 되기 때문에 제외했습니다. 대중성과 데이터의 연속성이 확보된 게임, 경제, 뷰티 등 핵심 10개 분야로 압축하여 예측의 신뢰도를 높였습니다.

Q5. 구글 트렌드(Google Trends) 데이터의 주차와 유튜브 API 데이터의 주차는 어떻게 시점을 동기화했나요?

 답변 가이드

두 데이터 모두 ISO week(월요일~일요일 기준 주차 구별 법)를 기준으로 변환하여 주차 축(year_week)을 통일한 뒤 카테고리별로 매핑(Merge)했습니다. 이를 통해 특정 주차에 발생한 외부 검색량이 해당 주차의 유튜브 반응 예측에 정확히 반영되도록 전처리했습니다.

Q6. Multi-head 구조를 사용하여 메인 타깃과 보조 타깃을 동시에 학습시켰다고 했는데, 두 타깃의 손실 함수(Loss Function) 배분은 어떻게 했나요?

 답변 가이드

둘 다 이진 분류(Binary Classification) 문제이므로 각각 Binary Cross Entropy Loss를 사용했습니다. 메인 타깃(rise_label)의 예측이 가장 중요하므로 메인 손실함수에 0.7, 보조 순위 상승 타깃(rank_up)에 0.3 정도의 가중치(Weight)를 부여하여 토탈 로스를 최소화하는 방식으로 멀티태스크 학습을 진행했습니다.

Q7. Precision@5가 0.900으로 매우 높은데, 이 모델이 '항상 조회수가 높은 대형 카테고리'만 안전하게 추천하는 편향(Bias)이 있지는 않나요?

 답변 가이드

아주 날카로운 지적 이십니다. 만약 절대 규모만 봤다면 매주 조회수가 가장 높은 뉴스나 게임 같은 카테고리만 추천되었을 것입니다. 하지만 저희 모델은 파생 변수로 '상대적 성장률'과 '가속도(momentum_ratio)', '순위 백분위'를 사용하기 때문에, 절대 규모는 작더라도 최근 반응이 회복되거나 치고 올라오는 '반려동물'이나 '교육' 같은 분야를 Top-5로 정확히 잡아낼 수 있었습니다.

Q8. 13번 슬라이드에서 반려동물, 먹방, 경제, 브이로그, 교육이 탑 5로 뽑혔는데, 분석가로서 이 결과가 합리적이라고 생각하나요?

 답변 가이드

네, 합리적이라고 판단합니다. 시각화 데이터를 보면 해당 카테고리들은 절대적인 반응 볼륨이 폭발하지 않았더라도, 구글 트렌드에서의 대중적 검색 관심도가 고개를 들기 시작했거나 내부 순위가 완만하게 상승 기류를 타는 지표들이 포착되었습니다. 단순 사후 분석이 아닌 '조짐'을 잡아낸 결과라는 점에서 타당성이 높습니다.

Q9. 데이터 규모가 통합 영상 약 16,000개 수준인데, 딥러닝 모델(BiGRU)을 학습시키기에 데이터 양이 다소 부족하여 과적합(Overfitting)이 발생하진 않았나요?

 답변 가이드

영상 개수는 16,641개이지만, 저희 모델의 실제 입력 단위는 영상 개별이 아닌 이들을 주차별-카테고리별로 압축한 '주간 시계열 행(5,770행)' 데이터입니다. 데이터의 행 수가 아주 많지는 않기 때문에 과적합을 방지하고자 드롭아웃(Dropout) 레이어를 적극 활용했고, 카테고리 임베딩 레이어의 차원을 낮게 설정하여 모델을 경량화하는 방식으로 오버피팅을 제어했습니다.

Q10. 향후 과제에서 '세부 콘텐츠 유형 단위의 예측'을 언급했는데, 이를 구현하기 위해 구체적으로 어떤 기술이나 데이터가 더 필요할까요?

 답변 가이드

현재는 거시적인 '요리' 카테고리라면, 앞으로는 그 안에서 '자취 요리', '레시피', '오마카세 리뷰' 같은 서브 키워드 단위로 쪼개야 합니다. 이를 위해 영상의 제목과 태그, 그리고 댓글 텍스트 데이터를 수집한 뒤, 자연어 처리(NLP) 기법인 토픽 모델링(LDA 등)이나 BERT 계열의 임베딩을 통해 세부 토픽 시계열을 먼저 추출하는 과정이 선행되어야 합니다.