




유튜브분야 상승 예측프로젝트



20221258 엄용현 20221295 홍찬기 20221292 이석준

주간 시계열과 외부 변수를 활용한 딥러닝 기반 Top-N 예측

CONTENT



1. 연구 배경 및 목적



2. 데이터 수집 및 구성



3. 데이터 전처리 및 EDA



4. 딥러닝 모델 설계 및 예측 기준




5. 모델 성능 평가 및 Top-N 예측 결과



6. 결론 및 향후 과제



연구 배경 및 목적



연구 배경 및 목적

유튜브 콘텐츠 시장은 빠르게 변화함 -> 분야별 관심도 또한 짧은 기간 안에 빠르게 변화

이미 유행한 콘텐츠 뒤따라가는 것 X 앞으로 상승할 가능성이 있는 분야 미리 파악 O

단순 조회수 중심 분석으로 변화 흐름, 상승 조짐을 설명하기 어려움

본 연구는 과거 추세 데이터, 최근 시계열 반응 활용하여 유튜브 분야 변화의 상승 가능성 분석

데이터 수집 및 구성



과거 추세, 최근 반응, 외부 변수를 통합한 유튜브 분야 예측 데이터 구성

유튜브 API 기반 영상 데이터	과거 카테고리 추세 데이터	최근 시계열 및 외부 변수 데이터
- 영상 메타데이터 수집 - 제목, 채널, 업로드 시점, 태그, 카테고리 - 반응 지표 수집 : 조회수, 좋아요, 댓글 등 영상 반응 지표 확보	2020~2025년 데이터를 기준으로 장기 흐름 분석 - 분야 변화 패턴 반영 : 카테고리별 관심도 변화와 기본 흐름 분석	- 최근 12주 추세 반영 카테고리별 최근 반응 흐름과 초기 반응 신호 활용 - 외부 변수 결합 Google Trends, 공휴일·연휴·방학·시험기간 변수 반영

- 데이터 기간: 과거 데이터 2020~2025, 최근 시계열 2026.4~5월
 - 데이터 규모: 전체 통합 영상 18,958, 중복 제거 16,641, 주간 추세 1,711, 시계열 지원 5,770
 - 최종 학습 대상: 활동 충분 16개 분야, 발표 핵심 10개 분야
 - 데이터 출처: YouTube Data API, 과거 수집 데이터셋, 시계열 추적 데이터, Google Trends
 - 추가 변수: 공휴일·연휴·방학·시험기간 기반 캘린더 변수

데이터 수집 및 구성 - 연구 범위 재정의



전체 분야 예측을 목표로 시작

BUT

분야별 활동량 편차를 고려해
더 신뢰도 높은 핵심 10개 분야
Top-5 예측
문제로 구체화

구분	내용
초기 목표	유튜브 전체 분야의 미래 관심도, 성장 가능성 예측
문제점	분야별 데이터 양과 활동량 차이 큼 -> 데이터가 적은 분야 주간 흐름 불안정
범위 조정 이유	예측 신뢰도 높이기위해 활동 충분한 16개 분야 선별, 발표 핵심 10개 분야를 최종 평가 대상으로 고정
최종 예측 문제	최근 12주 시계열과 외부 변수를 바탕으로 다음 4주 동안 상승 가능성이 높은 Top-5 분야를 선별하는 문제로 재정의

데이터정리및분류 - 전처리



전처리 단계	내용
데이터 통합 및 형식 정리	유튜브 전체 분야의 미래 관심도, 성장 가능성 예측
중복 제거 및 기준 정렬	동일한 영상은 video_id 기준으로 중복 제거 year_week 를 ISO week 기준으로 재정의하여 주차 축을 통일, category -week 시계열이 일관되게 연결되도록 정렬
시계열 및 외부 변수 결합	각 카테고리에 대해 최근 12주 추세를 입력 시퀀스로 구성 Google Trends 검색량과 공휴일, 연휴, 방학, 시험기간 기반 캘린더 변수를 함께 결합
핵심 카테고리 선별 및 특성 생성	16개 분야를 학습 대상으로 선정, 발표 핵심 10개 분야를 최종 평가 대상으로 설정
상승 라벨 및 학습셋 구성	현재 4주 평균 대비 다음 4주 평균의 상대 성장률을 기준으로 상승 여부 라벨을 생성

서로 다른 형태의 영상 데이터, 과거 추세 데이터, 외부 변수를 바로 학습에 활용하기 어렵기 때문에,
주차 기준 통합과 시계열 전처리 과정을 거쳐 최종 학습 데이터셋을 구성하였다

데이터 정리 및 분류 - 기본 변수 표



변수	내용
category	유튜브 분야 카테고리
avg_virality	해당 주차 카테고리의 평균 반응 규모
engagement_rate	좋아요·댓글 등을 반영한 참여도 지표
rolling_4week_mean	최근 4주 평균 반응 수준
search_interest	Google Trends 기반 검색 관심도
rise_label	다음 4주 상승 여부, 메인 타깃

변수	내용
year_week	ISO week 기준 주차 식별값
video_count	해당 주차 카테고리 내 영상 수
category_rank	주차별 카테고리 상대 순위
momentum_ratio	최근 반응 가속도 및 모멘텀 지표
holiday_days_in_week	해당 주차의 공휴일 수
rank_up	다음 4주 순위 상승 여부, 보조 타깃

데이터정리및분류 - 파생변수표




변수	내용
rolling_4week_mean	최근 4주 평균 반응 수준
rolling_4week_std	최근 4주 반응 변동성
trend_delta_1	직전 주 대비 변화량
momentum_ratio	최근 반응 가속도
competition_score	분야 내 경쟁 강도

변수	내용
opportunity_score	향후 상승 가능성 지표
rel_log_to_roll4	최근 평균 대비 현재 반응 수준
category_rank_pct	주차 내 상대 순위 백분위
search_roll4	최근 4주 평균 검색 관심도
rise_label	다음 4주 상승 여부

데이터정리및분류 - 파생변수표




최근 2년의 주간 평균 반응 규모와 주 비동휴일을 비교하여 분야별 흐름 차이를 확인



해석: 핵심 10개 분야는 동일한 방향으로 움직이지 않으며, 최근 구간에서도 상승 둔화 패턴이 서로 다르게 나타난다.

핵심 10개 분야의 공휴일 효과 추정치



해석: 공휴일 효과는 카테고리별로 방향과 크기가 다르게 나타나며, 이는 캘린더 변수를 최종 모델 입력에 포함한 근거가 된다.

핵심 10개 분야 최근 추세

최근 2년 동안 핵심 10개 분야의 평균 반응 흐름은 서로 다른 패턴
일부 분야는 특정 시점 **급격한 상승** 이후 **빠르게 둔화**,
다른 분야 비교적 안정적 흐름 유지

핵심 10개 분야의 공휴일 효과 추정치

최근 2년 구간에서 공휴일 주간과 비공휴일 주간의 평균 반응 수준 비교
분야별 공휴일 효과의 방향과 크기가 다르게 나타남
일부 분야 **공휴일 주간에 반응이 더 크게 증가**
내부 시계열 정보뿐 아니라 외부 일정의 영향도 받음

시사점

EDA 결과 유튜브 핵심 분야는 단순 규모 설명이 아닌 추세 변화와 외부 환경 고려해야 함
본 연구는 최근 12주 시계열, 구글 트렌드 검색량, 휴일 변수를 활용하여 **상승 가능성이 높은 분야 예측하고자 함**

딥러닝 모델 설계 및 예측 기준



WHAT

핵심 10개 유튜브 분야 중 앞으로
상승 가능성이 높은 분야
다음 4주의 상승 가능성 및 Top-N 분야

MODEL

BiGRU 기반 시계열 딥러닝 모델
Multi-head 구조 (상승 확률 & 순위 상승 확률 동시 산출)
Category Embedding 적용 (분야별 고유 특성 반영)

INPUT

내부 데이터: 최근 12주 카테고리 반응 추세
외부 변수: 구글 트렌드 검색량, 캘린더 변수

OUTPUT

상승 확률 및 순위 상승 확률
보조 랭킹 점수
최종 Top-N 상승 분야 선정 결과

딥러닝 모델 설계 및 예측 기준



예측 내용

기반 데이터: 최근 12주 시계열 + 외부 변수

예측 방식: 분야별 상승 확률 및 순위 상승 확률 산출

최종 목적: 데이터 조합을 통한 Top-N 상승 분야 선별

예측 대상

예측 단위/기간: 유튜브 핵심 10개 분야 / 다음 4주

대상 10개 분야:

게임, 경제, 교육, 뉴스시사, 먹방, 등

모델 성능 평가 및 Top-N 예측 결과



최종 코어 10개 BiGRU 모델 성능 요약

Accuracy

0.767

전체 예측 정확도

Balanced Acc.

0.798

불균형 보정 정확도

F1-score

0.829

정밀도·재현율 균형

ROC AUC

0.845

상승 분류 구분력

Top-N 선별 성능

Precision@5

0.900

상위 5개 중 적중률

Recall@5

0.801

실제 상승 분야 포착률

HitRate@5

1.000

상위 5개 내 포함 여부

NDCG@5

0.881

순위 품질 평가

모델 성능 평가 및 Top-N 예측 결과



상위 분야들은 최근 26주 구간에서 반응이 완전히 꺾이기보다, 유지되거나 회복되는 흐름을 보였다.

경제와 교육은 검색 관심도와 순위 상승 신호가 함께 관측, 반려동물과 먹방은 최근 반응 흐름이 비교적 안정적

최종 결과는 단순 조회수 규모가 아니라 최근 반응 추세, 검색 관심도, 상대 순위 신호를 함께 반영한 결과



따라서 본 모델은 현재 인기 분야를 반복 제시하는 것이 아니라, 향후 4주 동안 상대적으로 상승 가능성이 높은 분야를 선별하는 데 목적이 있다

TOP-5 예측 근거 시각화




최종 Top-5 상승 예측 분야의 최근 추세

반려동물, 먹방, 경제, 브이로그, 교육이 최종 상위권으로 예측되었으며, 최근 반응과 외부 관심도 흐름을 함께 제시


최종 Top-5 상승 예측 분야의 최근 반응 추세

최근 4주 평균을 100으로 한 상대 반응 지수




최종 Top-5 상승 예측 분야의 검색 관심도 추세

Google Trends 4주 이동 평균




최종 Top-5 상승 예측 분야의 카테고리 순위 추세

넷플릭스 인기 순위들 의미



해석: 최종 상위 분야는 단순 절대 규모가 아니라 최근 반응의 유지·회복 패턴, 검색 관심도, 상대 순위 신호를 함께 반영한 결과이다.

결론 및 향후 과제



상승 확률과 순위 상승 확률을 함께 반영하는 구조 적용

결과

Accuracy 0.767 TOP-5 선별 성능 Precision@5 0.900


Balanced Accuracy 0.798 NDCG@5 0.881

F1-score 0.829

ROC AUC 0.845

유튜브 분야 상승 가능성은 단순 규모 설명 X 장기 흐름, 최근 반응, 외부 관심도 등을 함께 고려

결론 및 향후 과제




더 긴 기간의 시계열 데이터 확보 -> 중장기 예측 안정성 높임

제목, 태그, 설명 등 텍스트 정보 정교하게 반영 -> 모델의 설명력, 예측 성능 개선

뉴스 이슈, 사회적 이벤트, 계절성 등 외부 변수 추가 -> 예측 범위 확장

향후에는 핵심 분야 예측 -> 세부 콘텐츠 유형 단위의 예측으로 확장



감사합니다